## Spark: Installation et Configuration

SOCIE

**BIG-DATA** 

El-Houssein Hamoudi C20536

### Plan de la Présentation

- 1. Introduction
- 2. Étapes d'Installation et Configuration
- 3. Implémentation PySpark
- 4. Implémentation Scala
- 5. <u>Démonstration</u>
- 6. Conclusion

#### Introduction

- Cette présentation documente l'installation et la configuration d'Apache Spark (version 3.5.0) dans un environnement Ubuntu Server virtualisé. L'objectif principal était de déployer un cluster Spark mono-nœud et de valider son bon fonctionnement via des exemples concrets en PySpark (Python) et Scala. Les étapes clés comprennent :
  - La création d'une machine virtuelle sous VirtualBox.
  - Le téléchargement des composants Hadoop/Spark et la configuration des chemins système (JAVA\_HOME, SPARK\_HOME).
  - L'exécution de scripts de traitement de données (recherche d'amis communs) pour tester le cluster.
  - La compilation de programmes Scala et leur soumission via spark-submit.

### Étapes Du travail

#### .1. Installation de la Machine Virtuelle

Installation d'Ubuntu Server sur VirtualBox.

#### 2 . Mise en Place de la Stack Logicielle

#### Commandes utilisées:

installation de spark

```
houssein@houssein-VirtualBox:~$ wget https://archive.apache.org/dist/spark/spark
-3.5.0/spark-3.5.0-bin-hadoop3.tgz
 -2025-06-30 19:27:53-- https://archive.apache.org/dist/spark/spark-3.5.0/spark
-3.5.0-bin-hadoop3.tgz
Resolving archive.apache.org (archive.apache.org)... 65.108.204.189, 2a01:4f9:1a
:a084::2
Connecting to archive.apache.org (archive.apache.org)|65.108.204.189|:443... con
nected.
HTTP request sent, awaiting response... 200 OK
Length: 400395283 (382M) [application/x-gzip]
Saving to: 'spark-3.5.0-bin-hadoop3.tgz'
spark-3.5.0-bin-had 100%[================] 381.85M
                                                         788KB/s
                                                                    in 17m 22s
2025-06-30 19:45:16 (375 KB/s) - 'spark-3.5.0-bin-hadoop3.tgz' saved [400395283/
400395283]
```

#### 3. extact le fichie

```
houssein@houssein-VirtualBox:~$ tar xzf spark-3.5.0-bin-hadoop3.tgz
noussein@noussein-virtualBox:~$ ls
                                Public
Backups
                                publickey
Desktop
Documents
                                server private.key
                                server public.key
Downloads
hadoop-3.2.1.tar.gz
                                snap
                                spark-3.5.0-bin-hadoop3
Music
mysql-connector-j-8.3.0
                                spark-3.5.0-bin-hadoop3.tgz
mysql-connector-j-8.3.0.tar.gz
                                Templates
Pictures
                                tp-1.0.0.jar
poeme.txt
                                Videos
privatekey
```

Configuration: Variables dans ~/.bashrc

```
GNU nano 7.2
                              /home/houssein/.bashrc
export HADOOP HOME=/usr/local/hadoop
.export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP COMMON HOME=$HADOOP HOME
export HADOOP HDFS HOME=$HADOOP_HOME
export YARN HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export PATH=SPATH:SHADOOP HOME/sbin:SHADOOP HOME/bin
export JAVA HOME=/usr/lib/jvm/java-17-openjdk-amd64
export JAVA HOME=/usr/lib/jvm/java-17-openjdk-amd64
export SPARK_HOME=/home/houssein/spark-3.5.0-bin-hadoop3
export PATH=$PATH:$SPARK_HOME/bin
export JAVA HOME=/usr/lib/jvm/java-17-openjdk-amd64
export SPARK HOME=/home/houssein/spark-3.5.0-bin-hadoop3
export PATH=$PATH:$SPARK_HOME/bin
```

charger spark ——

houssein@houssein-VirtualBox:~\$ source ~/.bashrc

V´erification: spark-shell

charger spark ——

houssein@houssein-VirtualBox:~\$ source ~/.bashrc

V´erification: spark-shell

Pip install pyspark



#### Exemple de test

```
houssein@houssein-VirtualBox:~$ cat output/mutual_friends/part-00000
1Sidi2Mohamed 3
```

### Etapes Du travail: implementation Scala

Install scala

houssein@houssein-VirtualBox:~\$ scala -version

Scala code runner version 2.12.18 -- Copyright 2002-2023, LAMP/EPFL and Lightbend, Inc.

houssein@houssein-VirtualBox:~\$ java -version

openjdk version "17.0.15" 2025-04-15

Compiler le programme en scala

houssein@houssein-VirtualBox:~\$ scalac -classpath "/\$SPARK\_HOME/jars/\*" /home/houssein/Desktop/mutual\_friends.scala

Créer un fichier JAR

houssein@houssein-VirtualBox:~\$ jar -cvf MutualFriends.jar \*.class

### Étapes Du travail :implementation Scala

#### Exécuter avec spark-submit

houssein@houssein-VirtualBox:~\$ spark-submit --class MutualFriends Mutu alFriends.jar

### Demonstration